

# **Éléments de Théorie des Langages – Partie 1**

- **Introduction générale : alphabets, mots et langages**
- **Langages rationnels**

# Alphabet, mot sur un alphabet (1)

---

Un **alphabet** est un ensemble (fini) **A** de symboles appelés **lettres**.

Un **mot** **m** sur un alphabet **A** est une séquence (finie) de lettres prises dans **A** : **m** = **a**<sub>1</sub> ... **a**<sub>k</sub>. Ce mot est de **longueur** (nombre de lettres) **k** : **|m|** = **k**.

Il existe un unique mot de longueur nulle, le **mot vide**, noté **ε**.

On note **A\*** l'ensemble de tous les mots construits sur l'alphabet **A**. On note **A<sup>n</sup>** l'ensemble des mots de **A\*** de longueur **n**.

En particulier, **A<sup>0</sup> = { ε }** (et donc **A<sup>0</sup> ≠ ∅** !) et **A<sup>1</sup> = A**.

## Alphabet, mot sur un alphabet (2)

---

Soit  $a$  une lettre de  $A$  et  $m$  un mot de  $A^*$ . Le **nombre d'occurrences** de la lettre  $a$  dans  $m$ , noté  $|m|_a$ , est le nombre de fois où la lettre  $a$  apparaît dans  $m$ .

Notons que  $|\varepsilon| = 0$  et, pour toute lettre  $a$ ,  $|\varepsilon|_a = 0$ .

**Exemples.**

$$A_1 = \{ 0, 1 \}$$

$$m_1 = 00101011, \quad m_2 = 1101$$

$$|m_1| = 8, \quad |m_2|_1 = 3$$

## Alphabet, mot sur un alphabet (3)

---

$$A_2 = \{ a, b, c \}$$

$$m_3 = \text{baba}, \quad m_4 = \text{bac}$$

$$|m_4| = 3, \quad |m_3|_a = |m_3|_b = 2$$

$$A_3 = \{ 0, \dots, 9, +, -, *, :, (, ) \}$$

$$m_5 = ( 12 + 4 ) * ( 71 - 14:5 )$$

$$|m_5| = 16$$

$$A_4 = \{ \text{si, alors, sinon, } >, a, b, \leftarrow, +, 0, 1, \dots \}$$

$$m_6 = \text{si } a > b + 1 \text{ alors } a \leftarrow 0 \text{ sinon } b \leftarrow 10$$

$$|m_6| = 15$$

# Concaténation de mots

---

Soient  $u$  et  $v$  deux mots de  $A^*$ . La **concaténation** de  $u$  et  $v$  est le mot, noté  $u.v$  ou plus simplement  $uv$ , obtenu en « collant » le mot  $v$  à la suite de  $u$ . Ainsi,  $|uv| = |u| + |v|$  et, pour toute lettre  $a$ ,  $|uv|_a = |u|_a + |v|_a$ .

On notera  $u^n$  le mot  $u.u. \dots .u$  ( $n$  fois), avec  $u^0 = \varepsilon$ .

**Exemple.**  $u = aba, v = ca, uv = abaca, u^2 = abaaba$   
 $|u| = 3, |v| = 2, |uv| = 5, |u^2| = 6$

Pour tous mots  $u, v$  et  $w$ , nous avons :

- $\varepsilon u = u\varepsilon = u$  ( $\varepsilon$  est élément neutre)
- $u.vw = uv.w = uvw$  (associativité)
- mais, en général,  $uv \neq vu$  (non commutativité)

# Préfixes, suffixes et facteurs

---

Soient  $u$  et  $v$  deux mots de  $A^*$ .

Le mot  $u$  est un **préfixe** du mot  $v$  s'il existe un mot  $w$  de  $A^*$  tel que  $v = uw$ .

De façon similaire, le mot  $w$  est un **suffixe** du mot  $v$  s'il existe un mot  $u$  de  $A^*$  tel que  $v = uw$ .

Le mot  $u$  est un **facteur** du mot  $v$  s'il existe deux mots  $w_1$  et  $w_2$  de  $A^*$  tels que  $v = w_1uw_2$ .

## Exemples.

- **aba** est un *préfixe* (et un *facteur*) de **abacabac** : **ab**acabac
- **bac** est un *suffixe* (et un *facteur*) de **abacabac** : abacab**ac**
- **aca** est un *facteur* de **abacabac** : ab**aca**bac

## Quelques propriétés...

**Proposition 1.** Si  $u$ ,  $v$  et  $w$  sont trois mots de  $A^*$ , alors

$$uw = vw \Leftrightarrow wu = wv \Leftrightarrow u = v$$

**Lemme de Levi.** Si  $u$  et  $v$  sont tous deux préfixes de  $w$ , alors  $u$  est préfixe de  $v$ , ou  $v$  est préfixe de  $u$  (les deux si  $u = v$ ).

**Théorème (de commutation).** Si  $u$  et  $v$  commutent (c'est-à-dire sont tels que  $uv = vu$ ), alors  $u$  et  $v$  sont deux *puissances* d'un même facteur :

$$uv = vu \Leftrightarrow \text{il existe un mot } f \text{ de } A^* \text{ et deux entiers } p \text{ et } q, p, q \geq 0, \text{ tels que } u = f^p \text{ et } v = f^q.$$

## Preuve du théorème de commutation...

---

- ( $\Leftarrow$ ) Si  $\mathbf{u} = \mathbf{f}^p$  et  $\mathbf{v} = \mathbf{f}^q$ , alors  $\mathbf{uv} = \mathbf{vu} = \mathbf{f}^{p+q}$ .
- ( $\Rightarrow$ ) Par récurrence sur  $\mathbf{N} = |\mathbf{u}| + |\mathbf{v}|$  :
  - si  $\mathbf{N} = 0$ , alors  $\mathbf{u} = \mathbf{v} = \varepsilon$  et donc  $\mathbf{u} = \mathbf{v} = \mathbf{u}^0$ .
  - si  $\mathbf{u} = \varepsilon$ , alors  $\mathbf{u} = \mathbf{v}^0$  et  $\mathbf{v} = \mathbf{v}^1$  (similaire si  $\mathbf{v} = \varepsilon$ ).
  - si  $|\mathbf{u}| = |\mathbf{v}| > 0$ , alors  $\mathbf{uv} = \mathbf{vu}$  entraîne  $\mathbf{u} = \mathbf{v}$ , par le Lemme de Levi, et donc  $\mathbf{u} = \mathbf{v} = \mathbf{u}^1$ .
  - sinon, comme  $\mathbf{u}$  et  $\mathbf{v}$  sont préfixes de  $\mathbf{uv} = \mathbf{vu}$ , l'un est préfixe de l'autre (Lemme de Levi).

Supposons, sans perte de généralité, que  $\mathbf{v} = \mathbf{uw}$ .

On a donc  $\mathbf{uv} = \mathbf{vu} \Rightarrow \mathbf{u(uw)} = (\mathbf{uw})\mathbf{u}$ , c'est-à-dire  $\mathbf{uuw} = \mathbf{uwu}$ , et donc  $\mathbf{uw} = \mathbf{wu}$  (Proposition 1).

L'hypothèse de récurrence permet alors de conclure.



# Langages (1)

---

Un **langage**  $L$  sur un alphabet  $A$  est un sous-ensemble, fini ou infini, de  $A^*$ .

Par exemple, sur l'alphabet  $A = \{a, b\}$ , on peut définir les langages suivants :

- $L_1 = A^2 = \{aa, ab, ba, bb\}$ ,
- $L_2 = \{ \text{mots d'au plus quatre lettres ayant autant de } a \text{ que de } b \}$   
 $= \{\epsilon, ab, ba, aabb, abab, abba, baab, baba, bbaa\}$ ,
- $L_3 = \{ \text{mots ayant deux fois plus de } a \text{ que de } b \}$   
(ce langage est infini).

## Langages (2)

---

Autres exemples :

- $A = \{ a, \dots, z \}$   
 $L = \{ \text{mots de la langue française} \}$
- $A = \{ \text{mots de la langue française} \}$   
 $L = \{ \text{phrases correctes} \}$
- $A = \{ \dots \}$   
 $L = \{ \text{programmes C++ syntaxiquement corrects} \}$
- etc.

# Opérations sur les langages (1)

---

Soit **A** un alphabet. On définit les opérations suivantes sur les langages définis sur **A**\* :

**Union.**

$$L_1 \cup L_2 = \{ m \in A^* / (m \in L_1) \text{ ou } (m \in L_2) \}$$

*Exemple.*  $\{ a, ba, ac \} \cup \{ b, c, ba, a \} = \{ a, b, c, ba, ac \}$

**Intersection.**

$$L_1 \cap L_2 = \{ m \in A^* / (m \in L_1) \text{ et } (m \in L_2) \}$$

*Exemple.*  $\{ a, ba, ac \} \cap \{ b, c, ba, a \} = \{ a, ba \}$

**Produit (de concaténation).**

$$L_1 \cdot L_2 = L_1 L_2 = \{ m \in A^* / m = m_1 m_2, m_1 \in L_1 \text{ et } m_2 \in L_2 \}$$

*Exemple.*  $\{ a, b, ba \} \cdot \{ b, ab \} = \{ ab, aab, bb, bab, baab \}$

# Opérations sur les langages (2)

---

**Puissance.**

$$L^0 = \{ \varepsilon \}$$

$$L^n = \{ m \in A^* / m = m_1 m_2 \dots m_n, \}$$

avec  $m_i \in L$  pour tout  $i$ ,  $1 \leq i \leq n$  }, pour tout  $n \geq 1$

*Exemple.*  $\{ a, ba \}^2 = \{ aa, aba, baa, baba \}$

**Étoile et "plus".**

$$L^* = L^0 \cup L^1 \cup \dots \cup L^n \cup \dots$$

$$L^+ = L^1 \cup L^2 \cup \dots \cup L^n \cup \dots$$

*Exemples.*  $\{ a, bc \}^* = \{ \varepsilon, a, bc, abc, bca, aaa, aabc \dots \}$

$\{ a, bc \}^+ = \{ a, bc, abc, bca, aaa, aabc \dots \}$

$\Rightarrow$  Observons que  $L^+ = L.L^*$